

Отчет по результатам практической работы

1. Описание задачи

Описание:

В файле «data_for_test.xlsx» представлены временные ряды предикторов и целевого показателя (суммарное количество телефонных звонков возможных покупателей в дилерские центры, реализующие автомобиль определённой марки).

Задача:

Построить регрессионную модель предсказания зависимой величины с помощью предоставленных факторов.

Датасет:

6 столбцов, 762 строки

Признаки:

- `Date` – дата
- `TV` – оценка числа контактов (в тысячах) с целевой аудиторией через ТВ-рекламу
- `OOH` – оценка числа контактов (в тысячах) с целевой аудиторией через наружную рекламу за указанный месяц
- `Seasonal_Sales` – оценка сезонной составляющей продаж автомобилей изучаемой марки в помесячной детализации (от 0 до 1)
- `Usd_rate` – курс доллара по Yahoo Finance (рублей за 1 доллар)
- `Y` – количество звонков (целевая переменная)

Типы данных:

`Date` - datetime, `TV` - int, остальные – float

	Date	Y	TV	OOH	Seasonal_Sales	Usd_rate
0	2013-01-01	NaN	0	0.0	0.060802	30.502001
1	2013-01-02	0.0	0	0.0	0.060802	30.337200
2	2013-01-03	17.0	0	0.0	0.060802	30.156500
3	2013-01-04	17.0	0	0.0	0.060802	30.271000
4	2013-01-05	8.0	0	0.0	0.060802	30.271000


```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 762 entries, 0 to 761
Data columns (total 6 columns):
 #   Column      Non-Null Count  Dtype  
--- 
 0   Date        762 non-null    datetime64[ns]
 1   Y           759 non-null    float64
 2   TV          762 non-null    int64  
 3   OOH         762 non-null    float64
 4   Seasonal_Sales 762 non-null  float64
 5   Usd_rate    762 non-null    float64
dtypes: datetime64[ns](1), float64(4), int64(1)
memory usage: 35.8 KB
```

Есть 3 пропуска в целевой переменной. Обычное удаление пропусков можешь повлечь разрушение монотонности данных. Дальше посмотрим, можно ли их чем-то заменить.

Что можно сделать:

- 1) Сделать из `Data` индекс
- 2) Преобразовать тип данных в `Y` из float в int, т.к. по описанию данных это количество звонков - значение всегда должно быть целочисленным.

2. Результаты исследовательского анализа данных

Date – Дата

Даты последовательны и не повторяются.

Первая и последняя дата соответствуют заявленным в описании.


Даты идут подряд от 01.01.2013 до 01.02.2015 без перерыва.

```
print ('Первая дата:', df.index.min())
print ('Последняя дата:', df.index.max())
print ('Временной отрезок:', df.index.max() - df.index.min())
```

```
Первая дата: 2013-01-01 00:00:00
Последняя дата: 2015-02-01 00:00:00
Временной отрезок: 761 days 00:00:00
```

TV – показатель медиаактивности на ТВ

Всего в 8.27% датасета есть информация о ненулевой оценке числа контактов через ТВ, в остальном это значение равно нулю:




Наблюдается 3 всплеска активности контактов, пришедших через ТВ:




- 1) 2013: 17 февраля - 11 марта, - от 5000 до 22000 тыс контактов
- 2) 2014: 23 июня - 13 июля, - от 10000 до 20000 тыс контактов
- 3) 2014: 24 ноября - 14 декабря, - от 7000 до 26000 тыс контактов


Частный случай всплеска контактов на временном отрезке:



Частный случай всплеска контактов на временном отрезке 2:



Частный случай всплеска контактов на временном отрезке 3:



- Наибольший разброс и наивысшее количество контактов в день видим в ноябре-декабре 2014 (последний график).
- Пик - 14 декабря 2014 (последний график).
- Наибольший минимум контактов в день - июнь-июль 2014 (2 график).

Изменение степени влияния рекламной активности на ТВ:

Корреляция TV и Y:

январь-август 2013: 0.284

май-сентябрь 2014: 0.0

октябрь 2014 - февраль 2015: 0.52



Октябрь 2014 – февраль 2015: корреляция наивысшая.

Январь-август 2013: эффективность рекламы в два раза ниже.

Май-сентябрь 2014: наименьшее влияние ТВ-рекламы на количество звонков.

ООН – Наружная реклама

В 42% месяцев в представленном датасете число контактов по наружной рекламе равно нулю:



Пики контактов:

2013: март; 2014: март, апрель, июль

Самое большое значение:

145.137 млн контактов в месяц





Медианное значение:

2460750 контактов в месяц

Среднее:

13734923.077 контактов в месяц. Сильно завышается из-за пика в июле 2014

Seasonal_Sales – сезонная составляющая



По большей части нормированная оценка сезонной составляющей продаж автомобиля не превышает значения 0.5.

В половине случаев она ниже 0.36.

Максимум:

1

Среднее и медианное:

0.46 и 0.36 соответственно


Видим наличие сезонности:

- 1) низкие значения в январе-феврале
- 2) скачок в марте
- 3) снижение к июлю
- 4) повышение до пикового значения в октябре
- 5) спад в январе

Доля выше 0.5 в месяцах:


март, апрель, сентябрь, октябрь, ноябрь, декабрь

Usd_rate – курс доллара




- Курс доллара начал явный рост после июля 2014.
- К февралю 2015 вырос примерно в два раза в сравнении с январем 2013.

Y – количество звонков, целевая переменная



Распределение:


- от 0 до 176 в день
- в среднем - 23.6 в день
- в половине случаев - 16 до 27



На графике видим по крайней мере 3 явных выброса. Это может быть ошибка в данных (например, значения увеличены в 10 раз), но корректировать на всякий случай не будем: данные могут быть реальны и связаны с каким-то другим событием, не указанным в датасете.


Среднее количество звонков:

- относительно высокое в марте-апреле 2013.
- спад - с апреля 2013 по ноябрь 2013.
- явный быстрый рост - с ноября 2013 по январь 2014.



Тренд:

- видим сильный рост к концу 2013 года. Однако, его нельзя назвать устойчивым, т.к. в январе резко пошел на спад.



Шум:

- резкие скачки звонков в апреле и августе 2013, марта 2014. Наблюдается большой разброс в последние месяцы 2014.



Сезонность, месячная:

- С понедельника по четверг включительно - количество звонков наибольшее
- Пятница - спад
- Выходные - низкое количествено звонков

Зависимости целевого признака от входящих

Курс доллара:



- имеет сильную корреляцию со скачком количества звонков в ноябре-декабре 2014.


Наружная реклама:



- Увеличение контактов с аудиторией в марте-апреле 2014 совпадает со скачком количества суммарных звонков в этот же временной промежуток.

Число контактов по ТВ:

Графики количества звонков и числа контактов по ТВ




- Кажется, слабо влияет на количество звонков. В последней рекламной кампании могло повлиять на рост количества звонков в совокупности с курсом доллара.

Число контактов по ТВ и Наружная реклама:



Графики количества звонков и числа контактов по ТВ



- в 2 случаях совпадают по времени с увеличением контактов через наружную рекламу. Возможно, их увеличение в марте 2013 повлияло на дальнейший пик в количестве звонков.

Общий вывод по исследовательскому анализу

Данные представлены во временном промежутке 761 дня:

- с 1 января 2013 по 1 февраля 2015

Всего было 3 рекламные кампании по ТВ: 17 февраля - 11 марта 2013 , 23 июня - 13 июля 2014, 24 ноября - 14 декабря. Оценка ежедневного количества с целевой аудиторией по этому каналу в дни кампаний – от 5 до 26 млн контактов.

В первой ТВ-кампании корреляция с целевым признаком составила 0.284, во второй – 0.0, в третьей – 0.52.

В 42% месяцев в представленном датасете число контактов по наружной рекламе равно нулю. Всего наружная реклама проводилась в 13 из 25 представленных в датасете месяцев. В среднем – 145.137 млн контактов в месяц. Пики – 2013: март; 2014: март, апрель, июль.

По большей части нормированная оценка сезонной составляющей продаж автомобиля не превышает значения 0.5. В половине случаев она ниже 0.36. Доля выше 0.5 в месяцах: март, апрель, сентябрь, октябрь, ноябрь, декабрь. Видим наличие сезонности: 1) низкие значения в январе-феврале, 2) скачок в марте, 3) снижение к июлю, 4) повышение до пикового значения в октябре, 5) спад в январе.

Курс доллара начал явный рост после июля 2014. К февралю 2015 вырос примерно в два раза в сравнении с январем 2013. С этим ростом связан и сильный рост количества звонков в ноябре-декабре 2014.

На графике целевого признака от даты есть явные 3 явных выброса. Видим сильный рост к концу 2013 года. Однако, его нельзя назвать устойчивым, т.к. в январе резко пошел на спад.

Явно прослеживается сезонность по количеству звонков в течение недели:

С понедельника по четверг включительно - количество звонков наибольшее. Пятница – спад. Выходные - низкое количество звонков

Взаимосвязи целевого признака со входными:

- Увеличение контактов с аудиторией по наружной рекламе в марте-апреле 2014 совпадает со скачком количества суммарных звонков в этот же временной промежуток.
- Увеличение количества звонков имеет сильную корреляцию со скачком количества звонков в ноябре-декабре 2014.
- Число контактов по ТВ, кажется, слабо влияет на количество звонков. В последней рекламной кампании могло повлиять на рост количества звонков в совокупности с курсом доллара.
- Число контактов по ТВ и Наружная реклама в 2 случаях совпадают по времени с увеличением контактов через наружную рекламу. Возможно, их увеличение в марте 2013 повлияло на дальнейший пик в количестве звонков.

3. Создание новых признаков

Рост курса доллара:

- 'Usd_rate_growth_d' – как изменился курс в сравнении с предыдущим днем.

Отстающие значения:

Y – количество звонков (целевая переменная):

- 'Y_lag_{i}' – 1, 2, 3, 4, 5, 7, 8, 14, 21, 30 дней

TV – контакты через ТВ-рекламу:

- 'TV_lag_{i}' – 1, 2, 3, 5, 7, 14 дней

ООН – контакты через наружную рекламу:

- 'OOH_lag_30' – 21 день


4. Обучение модели – результат

Выбранная метрика:

- MAE – т.к. наименее чувствительна к выбросами и наиболее понятна для интерпретации.

Прим:

- обучение проходило дважды: с учетом трех выбросов, обнаруженных при анализе данных, и без этих выбросов (были заменены на значения недельной давности)



Параметры предобработки и разбиения на выборки:

- размер тестовой выборки – 0.25
 - shuffle=False
 - масштабирование не применялось
-

1. С выбросами:

Обучены модели со следующими метриками на кросс-валидации:

- LinearRegressor:
 - MAE = 7.01
- LightGBM Regressor:
 - MAE = 7.70
- CatBoostRegressor:
 - MAE = 6.64

2. Без выбросов:

Обучены модели со следующими метриками на кросс-валидации:

- LinearRegressor:
 - MAE = 5.88
- LightGBM Regressor:
 - MAE = 6.19
- CatBoostRegressor:
 - MAE = 5.85

Лучшая модель:

- CatBoost 2 ('depth': 16, 'iterations': 500, 'l2_leaf_reg': 20, 'learning_rate': 0.6)

3. Результаты на тесте

MAE = 11.76



4. Проверка на адекватность:

- MAE = 11.76 - предсказания модели
- MAE = 14.97 - предсказания константным средним значением

Видим, что модель чуть более эффективна, чем если бы всегда предсказывали константой - средним.

5. Анализ остатков



Сравнительная гистограмма:



Распределение значений модели близко к нормальному, в отличие от реальных данных, где значения распределены не очень равномерно.

Заметно ниже стандартное отклонение предсказанных значений: 4.5 против 21.

Распределение остатков:




Чаще модель преуменьшает значения.

Медиана распределения остатков - 1.2, довольно близко к нулю.

При этом среднее - 7.46, достаточно далеко от нуля.

- увеличение среднего остатков связано с тем, что модель плохо предсказала очень высокие значения декабря 2014 - при обучении она с такими значениями не сталкивалась.

Максимальное завышение количества звонков - 15.



Выводы:

1. Сравнительно неплохо модель предсказывает значения в период до ноября 2014, когда начался резкий скачок звонков.
 2. Модель не очень точна, но в основном верно определяет направления изменений количества звонков.
 3. Модель не смогла предсказать сильный рост в ноябре-декабре 2014. Скорее всего, именно это значительно ухудшило метрику на teste.
-

6. Анализ остатков без учета скачка ноябрь-декабрь 2014



- MAE = 5.61 - предсказания модели без учета ноября-декабря
- MAE = 6.71 - предсказания константным средним значением без учета ноября-декабря

Вывод:

- Метрика значительно выше без учета ноября-декабря - с теми месяцами модель явно не справляется.
- При этом значение метрике все равно не сильно лучше, чем при предсказании константным средним значением.
- Точно можно сказать, что модель неплохо предсказывает направление изменения количества звонков. В большинстве случаев справляется с определением пиковым количеством звонков (наибольших и наименьших).

7. Анализ важности признаков

Наиболее важные с точки зрения модели признаки:

Повышают значение целевой переменной высокие значения:


- количества звонков: вчерашнее, 3, 4, 5, 7, 8 дней назад
- количества контактов по ТВ: 7 дней назад

Повышают значение целевой переменной низкие значения:

- курса доллара
- количества звонков 30 дней назад
- оценки сезонной составляющей продаж

Изменение значения относительно среднего – **повышает** значение целевой переменной:

- TV, TV_lag_1, TV_lag_3, TV_lag_5, TV_lag_14



8. Возможности по улучшению модели

Добавить больше актуальных данных по 2015 году.

Возможно, добавить новый категориальный признак: рост доллара на критический процент (50-100%) в последние день/неделю/месяц/2 месяца . В связи с резким ростом курса доллара в конце года покупательское поведение изменилось – такой признак поможет в дальнейшем учесть подобные изменения. Но для этого также нужно больше данных.

Если есть другие рекламные активности – учесть и их.

С имеющимся набором – можно дополнительно поработать над созданием новых признаков. Подобрать больше отстающих значений, скользящих средних.

Также количество отстающих значений можно нарастить до 365 – при этом удалится значительная часть датасета, но останутся данные по целому году и, возможно, модель сможет учсть какую-то сезонность по году (например, первые дни января всегда проседают по звонкам). Скорее всего, Y_log_365 может стать одним из ключевых признаков для модели.

Возможно, из ООН и TV тоже можно было бы попробовать сделать категориальный признак – идет ли реклама в текущем месяце.